

论文技术分析报告

基于 YOLOv8 与极值理论的集装箱破损智能检测模型

摘要：本报告对 2026 年高教社杯全国大学生数学建模竞赛 D 题的优秀论文进行技术分析。该论文构建了”检测—分类—评估”一体化的计算机视觉建模框架，依次解决破损有无判别、破损定位与类别识别、模型多维度评估三项任务。报告从模型架构、训练策略、损失函数设计、实验验证与系统评估五个方面展开技术剖析，揭示其创新点与工程价值。

一、研究背景与问题概述

1.1 问题背景

随着全球贸易的快速发展，集装箱作为国际货物运输的核心载体，在长期装卸、堆叠与运输过程中常产生裂纹、凹陷、穿孔、锈蚀等损伤。传统人工巡检存在效率低、主观性强、环境适应性差等问题，基于计算机视觉的自动检测方法成为研究热点。

1.2 三项建模任务

1. 问题一（分类任务）：判断集装箱图像是否存在任何形式的残损
2. 问题二（检测任务）：定位残损位置并识别残损类别
3. 问题三（评估任务）：从不同维度对所建模型进行评估

二、模型架构设计

2.1 整体框架

本文采用”检测—判别”两阶段框架：

- **检测阶段：**基于 YOLOv8 的目标检测网络，提取图像中破损的位置、类别与置信度
- **判别阶段：**基于极值理论（EVT）对置信度极值分布建模，实现开放集判别

2.2 YOLOv8 检测模型

YOLOv8 是 Ultralytics 提出的单阶段目标检测框架，采用 anchor-free 解耦检测头设计，整体由三部分组成：

表 2-1: YOLOv8 网络结构组成

组件	结构	功能
Backbone	Conv + C2f + SPPF	多尺度特征提取，感受野增强
Neck	PAN-FPN 双向融合	自顶向下与自底向上特征融合
Head	P3/P4/P5 解耦头	anchor-free 预测类别与包围框
后处理	NMS	非极大值抑制去重

2.3 总体训练损失

YOLOv8 的总体训练损失由定位损失、分类损失与分布聚焦损失三部分加权组成：

$$\mathcal{L} = \lambda_{\text{box}}\mathcal{L}_{\text{box}} + \lambda_{\text{cls}}\mathcal{L}_{\text{cls}} + \lambda_{\text{dfl}}\mathcal{L}_{\text{dfl}} \tag{1}$$

其中定位损失采用 CIOU 损失：

$$\mathcal{L}_{\text{CIOU}} = 1 - \text{IoU} + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{\text{gt}})}{c^2} + \alpha v \tag{2}$$

三、训练策略与改进方法

3.1 统一实验设置

表 3-2: 实验环境与统一训练超参数

类别	配置	类别	配置
GPU	RTX 4070 Laptop (8 GB)	输入尺寸	640 × 640
PyTorch	2.13	批大小	16
Ultralytics	8.4.110	初始学习率	0.01
优化器	SGD (momentum=0.937)	学习率衰减	余弦退火
混合精度	AMP	随机种子	42

3.2 三组递进对照实验

表 3-3: 三组实验配置

实验	骨干网络	训练轮数	Copy-Paste	负样本数
基线	YOLOv8n (3.01 M)	100	0	0
改进	YOLOv8s (11.13 M)	150	0.5	0
最终模型	YOLOv8s (11.13 M)	150	0.5	600

3.3 关键改进策略

3.3.1 Copy-Paste 数据增强

针对 Hole 类样本仅占 11.8% 的类别不平衡问题，采用基于实例混合的增强策略。设源图像中实例 $o = (I_o, B_o)$ ，目标图像为 I_t ，粘贴变换 $\mathcal{T}$ ，则生成样本为：

$$(I', B') = (I_t \oplus \mathcal{T}(I_o), B_t \cup \mathcal{T}(B_o)) \quad (3)$$

3.3.2 负样本参与训练

从训练图像中不覆盖任何标注框的区域随机裁剪 320×320 子图，构造 600 幅负样本并入训练集。检测网络据此学习抑制背景响应，使无缺陷图像的最大置信度整体下移。

四、损失函数设计

4.1 WD-Focal Loss

在 Focal Loss 基础上设计基于 Wasserstein 距离的自适应焦点损失：

$$\mathcal{L}_{\text{WD-FL}}(p_t, c) = -\alpha_c(1 - p_t)^\gamma \log p_t \quad (4)$$

其中类别平衡系数由 Wasserstein 距离动态调制：

$$\alpha_c = \sigma\left(\frac{W_1(\mu_c, \bar{\mu})}{\tau}\right) \quad (5)$$

4.2 Rusty 类加权

采用 BCE 损失，基于类别频率比设置 pos_weight：

$$\text{pos_weight} = [1.0, 1.0, 3934/3158] \approx [1.0, 1.0, 1.246] \quad (6)$$

五、实验结果与分析

5.1 三组实验对比

表 5-4: 三组实验验证集最优检测指标对比

实验	mAP@0.5	mAP@0.5:0.95
基线 (YOLOv8n)	0.395	0.190
改进 (YOLOv8s + CP)	0.413	0.212
最终模型 (+ 负样本)	0.405	0.205

5.2 逐类检测性能

表 5-5: 最终模型验证集逐类检测性能

类别	Precision	Recall	mAP@0.5	mAP@0.5:0.95	F1
Dent（凹陷）	0.628	0.518	0.517	0.295	0.568
Hole（破洞）	0.621	0.407	0.400	0.190	0.492
Rusty（锈蚀）	0.471	0.282	0.293	0.129	0.353
全部	0.573	0.402	0.403	0.204	—

5.3 消融实验结论

1. 骨干升级（YOLOv8n→YOLOv8s）带来 mAP@0.5:0.95 约 0.022 的提升
2. Copy-Paste 在本数据集（仅目标框标注）上未产生可观测增益，提升主要来自骨干容量升级
3. 负样本训练使纯正样本验证集 mAP 小幅下降约 0.007，但显著改善 EVT 判别效果

六、鲁棒性与效率评估

6.1 鲁棒性量化测试

表 6-6: 最终模型在扰动验证集上的鲁棒性结果（494 幅）

扰动类型	mAP@0.5	mAP@0.5:0.95
无扰动（基线）	0.403	0.204
高斯噪声 $\sigma = 10$	0.223	0.086
高斯噪声 $\sigma = 25$	0.077	0.023
高斯噪声 $\sigma = 50$	0.015	0.004
亮度 +30	0.398	0.200
亮度 -30	0.386	0.190
高斯模糊 3×3	0.414	0.204
高斯模糊 7×7	0.337	0.158

6.2 推理效率

表 6-7: 模型效率对比 (640×640, RTX 4070 Laptop GPU)

模型	参数量	计算量	端到端推理
基线 (YOLOv8n)	3.01 M	8.2 GFLOPs	8.95 ms (112 FPS)
最终模型 (YOLOv8s)	11.13 M	28.4 GFLOPs	8.87 ms (113 FPS)

七、技术优势与不足

7.1 主要优势

- 1. **创新性强:** EVT 在计算机视觉中的应用新颖独特, 解决开放集检测难题
- 2. **理论扎实:** 数学基础深厚, 推导严谨, 阈值设定有统计依据
- 3. **效果显著:** 在复杂港口场景下达到实用水平, 113 FPS 满足实时需求
- 4. **完整度高:** 从问题分析到模型部署全流程覆盖
- 5. **实验严谨:** 三组对照实验与六维度评估体系完整客观

7.2 存在不足

- 1. WD-Focal Loss 端到端效果不理想, 需重新配平损失尺度
- 2. 对高斯噪声敏感, $\sigma = 50$ 时 mAP 降至 0.004
- 3. Rusty 类召回率仅 0.282, 是整体性能主要短板
- 4. 伪负样本可能未完全代表真实”无缺陷”集装箱

八、总结

该论文是数学建模竞赛的典范之作, 体现了作者团队扎实的数学功底、深厚的机器学习造诣和优秀的工程实践能力。其将极值理论引入计算机视觉的创新思路, 不仅为竞赛提供了优秀解决方案, 更为工业检测领域的开放集问题提供了全新思路, 具有实际应用价值与学术参考意义。